

Zajęcie. Użycie Orange w celu eksploracji i wizualizacji danych

Abstract

Celem jest nabycie podstawowej znajomości Orange rozwiązując zadanie eksploracji i wizualizacji danych odpowiednio do określonego wariantu

1. Opic oprogramowania

Orange to wizualny język programowania do uczenia maszynowego, eksploracji danych i interaktywnej analizy.

Oprogramowanie zostało wprowadzone pod koniec lat 90. XX wieku i jest rozwijane na Uniwersytecie w Lublanie na Wydziale Informatyki i Nauk Informacyjnych w Laboratorium Bioinformatyki.

Orange jest jednym z największych środowisk open source do nauki o danych opartej na wizualizacji.

Oprogramowanie jest dostępne dla każdego bezpłatnie i pierwotnie zostało stworzone do celów edukacyjnych, choć nadal jest odpowiednim narzędziem do praktycznego przetwarzania danych.

2. Języki programowania

W oprogramowaniu wykorzystywane są języki programowania takie jak Python, Cython, C++ i C. Środowisko graficzne oprogramowania zostało stworzone z wykorzystaniem języka programowania Python oraz bibliotek Qt3

3. Funkcjonalności

W oprogramowaniu można wykonywać różne operacje, które są wyświetlane na lewym panelu. Operacje podzielone są na 18 grup, które różnią się od siebie kolorami. Grupa zawiera widżety oznaczone tym samym kolorem, co grupa, do której należą.

3.1. Operacje i widżety

Operacje są pogrupowane w grupy takie jak:

- Dane - folder, import CSV, tabela danych, informacje o pliku danych itp.
- Transformacja - wybierz wiersze, wybierz kolumny, połącz dane, połącz kolumny, połącz itp.
- Wizualizacja – diagram punktowy, diagram czasowy, diagram sieciowy, diagram Venna itp.
- Model – regresja liniowa, regresja logistyczna, metoda wektorów nośnych itp.
- Ocena - predykcja, krzywa ROC, wykres kalibracyjny, krzywa wydajności
- Nienadzorowane - korelacja, K-średnie, metoda Louvaina, grupowanie hierarchiczne itp.
- Spektroskopia - skalowanie wielowymiarowe, zmiana kształtu mapy itp.
- Eksploracja tekstu - import dokumentów, powielanie wyników, Wikipedia, wzbogacanie słów itp.
- Analiza przeżycia – diagram Kaplana-Meiera, regresja Coxa, kohorta itp.
- Bioinformatyka – zróżnicowana ekspresja genów, analiza skupień, zestaw genów itp.

- Pojedyncza komórka – ładuj dane, filtruj, łącz zbiory danych, wyniki genów itp.
- Analityka obrazu – przesyłaj obrazy, przeglądaj obrazy, zapisuj obrazy itp.
- Sieci - analiza sieci, klastrowanie sieci, generator sieci itp.
- Geo - geokodowanie, geomapa, kartogram itp.
- Edukacyjne – regresja wielomianowa, klasyfikacja wielomianowa, wykres kołowy, opadanie gradientu itp.
- Szeregi czasowe – wykres liniowy, periodogram, korelogram, spiralo-gram, interpolacja itp.
- Współpracownik - częste zestawy przedmiotów i zasady skojarzeń
- Wyjaśnienie – wyjaśnij model, znaczenie funkcji, wyjaśnij przewidywanie i wyjaśnij przewidywania

4. Strona projektu

<https://orangedatamining.com/>

5. Instalacja

W ramach ekosystemu Anaconda

6. Opis danych

Dane do zadania będą pobrane ze strony http://ghdx.healthdata.org/ihme_data która przedstawia sobą repozytorium danych socjoekonomicznych.

One zawierają dane badań statystycznych w zakresie gospodarki, demografii oraz służby zdrowia.

Dane mogą być przedstawione w postaci plików formatów .csv lub .xlsx

7. Warianty Zadania

Zadanie dotyczy pobrania danych z pliku, tworzenia pipeline z wyświetleniem wykresu punktowego oraz histogramu na podstawie odpowiedniego zbioru danych:

Warianty

1. Development Assistance for Health Database 1990-2020
2. Gross Domestic Product Per Capita 1960-2050
3. Global Health Spending 1995-2018
4. United States Healthcare Spending by Race and Ethnicity 2002-2016
5. Global Young People Smoking Prevalence and Initiation Age 1990-2019
6. Global Burden of Disease Study 2019 (GBD 2019) Chewing Tobacco Use Prevalence 1990-2019
7. Global Burden of Disease Study 2019 (GBD 2019) Smoking Tobacco Use Prevalence 1990-2019
8. ORB General Population COVID-19 Health Services Disruption Survey 2020
9. Premise Women's Health COVID-19 Health Services Disruption Survey 2020

10. Premise Child Health COVID-19 Health Services Disruption Survey 2020
11. Premise General Population COVID-19 Health Services Disruption Survey 2020
12. United States COVID-19 Scenarios 2020-2021
13. Global Burden of Disease Study 2019 (GBD 2019) Relative Risks
14. United States Health-Care Spending Attributable to Modifiable Risk Factors 2016
15. Global Child Growth Failure Geospatial Estimates 2000-2019
16. Low- and Middle-Income Country Drinking Water and Sanitation Facilities Access Geospatial Estimates 2000-2017
17. Low- and Middle-Income Country Oral Rehydration Therapy Coverage Geospatial Estimates 2000-2017
18. Global Fertility, Mortality, Migration, and Population Forecasts 2017-2100

Sprawozdania w postaci:

1. Sprawozdanie (plik .pdf)

zachować w zdalnym repozytorium (np Github) link na który umieścić w sprawozdaniu. Sprawozdanie należy wysłać na e-uczelnię zgodnie z ustalonym terminem.

References

References